




Obučavanje agenata u interaktivnom okruženju korišćenjem učenja uslovljavanjem

Lazar Nagulov SV61/2022

Filip Tot SV14/2022



Uvod

- Cilj je obučiti agenta u interaktivnom 3D okruženju da izvršava kompleksne zadatke — od kretanja, izbegavanja neprijatelja, do preciznog gađanja meta.
- **Tehnologije:**
 - Unity
 - MLAgents



Pristup i metodologija

- Učenje uslovljavanje (eng. Reinforcement Learning)
 - Agent posmatra svet putem vektora (ugao, distanca, prisustvo neprijatelja...)
 - Akcije su kretanje, skok i pucanje.
 - Nagrade se dodeljuju za uspeh, a kazne za greške ili otkrivanje od strane neprijatelja.
- PPO (Proximal Policy Optimization) algoritam.
- Kako bi se agent postepeno prilagodio složenijim zadacima, primenjen je pristup *Curriculum Learning*
 - Agent najpre savladava jednostavne zadatke, a zatim se izlaže kompleksnijim scenama koje uvode nove elemente ponašanja.



Definicija funkcije nagrade

- Agent dobija pozitivne nagrade za napredak i uspehe, a kazne za neuspehe i neefikasno ponašanje.
- Vrednosti nagrada su dinamičke i zavise od scene. U ranim fazama agent se više nagrađuje za navigaciju, dok se u kasnijim scenama naglasak prebacuje na preciznost i efikasnost gađanja.

$$R_{\text{total}} = R_{\text{goal}} + R_{\text{targets}} + R_{\text{enemies}} + R_{\text{distance}} - P_{\text{failures}}$$

- Korišćene nagrade:

- Pobeda
- Checkpoint
- Pogođena meta
- Pogođene sve mete
- Pogođen neprijatelj
- Eliminisan neprijatelj
- Udaljenost do cilja

- Korišćene kazne:

- Pad sa mape
- Ekzistencija
- Isteklo vreme
- Pad u reku
- Neprijatelj u blizini
- Neprijatelj je napao agenta
- Mala kazna za skok
- Mala kazna za ispaljenu strelu



Definicija posmatranja

- Agent ne vidi čitav svet, već dobija skup numeričkih posmatranja koja opisuju okruženje.
- Posmatranja mogu da budu diskretna i neprekidna
 - Sva neprekidna posmatranja se normalizuju na $[-1, 1]$
 - Na primer, udaljenost do cilja je vrednost $[0, 1]$.
- Agent može da vidi objekte ispred sebe pomoću posmatranja zasnovanog na zrakovima (eng. Ray perception).

```
sensor.AddObservation(nearestTarget == null ? 0 : 1);
sensor.AddObservation(AngleBetweenHorizontal(player, nearestTarget, 0f));
sensor.AddObservation(AngleBetweenVertical(player, nearestTarget, 0f));
sensor.AddObservation(DistanceBetween(player, nearestTarget, -1f));

sensor.AddObservation(nearestEnemy == null ? 0 : 1);
sensor.AddObservation(AngleBetweenHorizontal(player, nearestEnemy, 0f));
sensor.AddObservation(AngleBetweenVertical(player, nearestEnemy, 0f));
sensor.AddObservation(DistanceBetween(player, nearestEnemy, -1f));


sensor.AddObservation(AngleBetweenHorizontal(player, currentGoal, 0f));
sensor.AddObservation(AngleBetweenVertical(player, currentGoal, 0f));
sensor.AddObservation(DistanceBetween(player, currentGoal, -1f));
```

- Najbliža meta
- Najbliži neprijatelj
- Udaljenost od cilja






Definicija akcija


- Agent na osnovu posmatranja i naučenih relacija, određuje koje akcije će da izvrši. Akcije su predstavljanje preko niza numeričkih vrednosti.
- Kao i posmatranja, i akcije mogu da budu diskretne i neprekidne.
 - Diskretne akcije su celi brojevi od 0 do veličine diskretne grane
 - Neprekidne akcije decimalni brojevi u opsegu $[-1, 1]$
- Akcije koje je su korišćene u projektu:
 - Kretanje po dve ose
 - Okretanje igrača horizontalno
 - Okretanje kamere vertikalno
 - Skok
 - Da li gađati strelu
 - Kojoj snagom gađati strelu




Evaluacija i metrike

- Praćene su ključne metrike tokom treninga
 - stopa uspešnosti, kumulativna nagrada i dužina epizode
- Za svaku scenu su odvojeni ključni grafici - dužina epizode, vrednost funkcije nagrade...






Dužina epizode



Funkcija nagrade




Procenat uspešnosti

Scena 1 - Kretanje


- Agent uči osnovno kretanje i kako da dođe do cilja
- Scena je jednostavna, samo agent i cilj
- Agent i cilj sve stvaraju svaki put na random mestima

Scena 2 - Neprijatelji


- Na scenu se dodaju neprijatelji.
- Neprijatelji se kreću ka agentu kada su u blizini, u suprotnom patroliraju.




Broj detekcija




Funkcija nagrade




Procenat uspešnosti



Funkcija nagrade



Dužina epizode




Procenat uspešnosti

Scena 3 - Skakanje


- Na scenu se dodaje reka koju agent treba da preskoči da bi došao do cilja.

Finalna scena


- Scena integriše sve naučene veštine u koherentan obrazac ponašanja




Procenat uspešnosti



Funkcija nagrade



Broj detekcija



Prosečan broj pogođenih meta

Analiza rezultata

- Postignuti rezultati:
 - **Stopa uspešnosti:** Agent je postigao visoku stopu uspešnosti (~95%) nakon približno 3 miliona koraka treninga
 - **Funkcija nagrade:** Stabilizacija kumulativne nagrade na pozitivnim vrednostima ukazuje na konzistentno dobro ponašanje
 - **Izbegavanje detekcije:** Broj detekcija od strane neprijatelja opada tokom treninga, što pokazuje da agent uči strategije prikrivanja
- **Curriculum Learning pristup** se pokazao efikasnim - agent je uspešno progresirao od jednostavnih ka kompleksnim zadacima
- **PPO algoritam** je omogućio stabilno učenje bez značajnih oscilacija u performansama
- Agent je razvio kompleksne strategije koje kombinuju navigaciju, izbegavanje neprijatelja i precizno gađanje



Moguća poboljšanja

- Fine-tuning funkcije nagrade za još preciznije ponašanje
- Proširenje sa dodatnim tipovima prepreka i neprijatelja
- Dinamičko prilagođavanje nagrada - automatsko balansiranje težina funkcije nagrade tokom treninga
 - Trenutno postoji samo kod udaljenosti od cilja i različitih scena





Hvala na pažnji