



Obučavanje agenata u interaktivnom okruženju korišćenjem učenja uslovljavanjem

Lazar Nagulov SV61/2022

Filip Tot SV14/2022

Definicija problema

Problem koji se rešava odnosi se na razvoj agenata sposobnih da uče optimalne strategije ponašanja u dinamičkom i nepredvidivom okruženju. Cilj ovog projekta je da se kroz učenje uslovljavanjem (eng. *Reinforcement Learning*, *RL*) razviju agenti koji samostalno uče strategije kroz interakciju sa okolinom, bez eksplicitnog programiranja svih mogućih situacija.

Motivacija

Metode zasnovane na učenju uslovljavanjem imaju široku praktičnu primenu. Trening agenata u interaktivnim okruženjima omogućava istraživanje načina na koje sistemi mogu samostalno da uče kompleksne zadatke, što se može preneti na realne probleme u oblastima poput robotike, logistike ili medicine.

Skup podataka


Za rešavanje problema interakcije sa okolinom, ne može se primeniti skup podataka u standardnom smislu, već će se umesto toga koristiti okruženje sa kojim će agent interagovati. Kao skup podataka možemo definisati scene (okruženja) na kojima će agent biti podučavan, kao i scene na kojima će pokazivati svoje rešenje.

Način pretprocesiranja podataka

S obzirom da će agent učiti na skupu scena, ne možemo primeniti standardne metode pretprocesiranja, kao što je promena formata podataka, ali možemo promeniti način na koji će agent dobijati te podatke. Jedan primer ove promene podataka je mapiranje različitih elemenata scene na niz brojeva koji će agent dobijati. Definisanje ovog mapiranja vrši se pre samog treniranja. Drugi primer jeste označavanje nepotrebnih elemenata okruženja koje agent neće dobijati, čime možemo povećati efikasnost učenja.

Metodologija

Ideja je da agent kroz interakciju uči optimalnu strategiju koja mu omogućava da pogađa mete i istovremeno izbegava neprijatelje. Ovo se može podeliti u nekoliko procesa, od kojih su glavni: definisanje okruženja, definicija ulaza (posmatranje), definisanje izlaza (akcija), definisanje funkcija nagrade, odabir algoritma za treniranje, evaluacija i testiranje.



Slika 1 - Učenje uslovljavanjem[3]

Definisanje okruženja

Kreira se 3D scena u Unity-ju koja sadrži teren, mete, prepreke, cilj i jednog neprijatelja. Neprijatelj ima definisano ponašanje - vidokrug i patroliranje. Agent kontroliše igrača koji se može kretati i gađati mete, i koga pokušava da dovede do cilja.

Definicija ulaza (posmatranje)

Posmatranje (eng. *Observation*) je delimičan opis stanja, koji može izostaviti određene informacije. U učenju uslovljavanjem najčešće predstavljamo stanja i posmatranja pomoću vektora, matrice ili tenzora realnih vrednosti [3].

U ovom projektu agent koristi sledeće informacije:

- **Ugao i distanca do cilja** – relativna orijentacija i udaljenost ciljne pozicije u odnosu na agenta.
- **Informacije o neprijatelju** – binarni indikator da li je neprijatelj u blizini, ugao do najbližeg neprijatelja i njegova distanca.
- **Broj preostalih meta** – daje agentu uvid u progres zadatka.
- **Posmatranje pomoću zrakova (eng. *ray perception*)** – agent koristi zrake za detekciju prepreka i okruženja, čime dobija informaciju o položaju i vrsti objekata u neposrednoj okolini.

Struktura posmatranja može se proširiti tokom razvoja modela kako bi se poboljšale performanse, npr. dodavanjem informacija o brzini agenta, broju ispaljenih strela ili statusu otkrivenosti. Svako posmatranje se pre slanja agentu normalizuje na opseg $[-1,1]$ ili $[0,1]$, kako bi se smanjile razlike između različitih posmatranja i time obezbedilo stabilnije i efikasnije učenje agenta.

Definicija izlaza (akcije)

Na osnovu ulaza, algoritam određuje koje akcije treba da se izvrše. Akcije mogu da budu diskretne (npr. izbor između unapred definisanih mogućnosti kao što su kretanje napred, nazad, levo, desno) ili kontinualne (npr. podešavanje brzine kretanja ili ugla rotacije). Neke od akcija su kretanje napred/nazad/levo/desno, rotacija ili akcija gađanja strele. Kroz interakciju sa okruženjem i dobijanje povratne informacije u obliku nagrada, agent uči politiku (eng. *policy*) – funkciju koja određuje optimalnu akciju u datom stanju [1], [2].

Definisanje funkcija nagrade

Na osnovu izvršenih akcija agent se nagrađuje ili kažnjava. Pomoću ovoga agent uči koje akcije su korisne i koje ga dovode bliže cilju, kao i akcije koje su štetne. Svaki put kada agent uspe da uradi nešto značajno (pogodi metu, dođe do cilja), dobija proporcionalnu nagradu. Ovaj sistem nagrađivanja objašnjava agentu šta se od njega očekuje i koja ponašanja treba da ponovi, ili izbegava.

U tabeli 1 prikazan je primer načina dodele nagrada agentu u zavisnosti od konkretne situacije u kojoj se nalazi tokom epizode. Nagrade se definišu eksperimentalno tako da podstiču željeno ponašanje.

Situacija	Nagrada po akciji
Agent je ispao sa mape (kraj epizode)	-1
Agent je dotakao cilj (kraj epizode)	1
Agent je u blizini neprijatelja (~3m)	-0.01
Isteklo je vreme (kraj epizode)	-0.1
Neprijatelj je napao agenta	-0.05
Agent je pogodio metu	0.35
Nagrada postojanja	-0.001

Tabela 1 - Tabela dodele nagrada u zavisnosti od situacije

Ukupna vrednost nagradne funkcije za jednu epizodu definiše se kao zbir svih pojedinačnih nagrada koje agent ostvari tokom trajanja epizode. Ova suma predstavlja osnovu za evaluaciju performansi agenta i koristi se u procesu učenja.

Sama funkcija može da varira u zavisnosti od ponašanja agenta tokom razvoja projekta, na primer moguće je kažnjavati agenta za neke akcije koje ne želimo da često radi. Takođe, moguće je dodaljivanje nagrade dinamički, na primer dodeliti nagradu u zavisnosti od udaljenosti agenta od cilja.

Odabir algoritama za treniranje

Koristi se PPO (eng. *Proximal Policy Optimization*) algoritam implementiran u ML-Agents. Trening se izvodi na velikom broju epizoda u kojima agent uči balans između preciznog gađanja i izbegavanja neprijatelja, ali i kako da pronade rešenje.

Način evaluacije

Evaluacija razvijenog rešenja vršiće se na osnovu jasno definisanih i merljivih kriterijuma koji odražavaju uspešnost agenata. Za procenu uspešnosti agenta koristiće se:

- Glavne metrike
 - Prosečna ukupna nagrada po epizodi (eng. *Average Cumulative Reward*)
 - Procenat uspešno završenih epizoda (eng. *Success Rate*)
 - Prosečan broj koraka po epizodi (eng. *Episode Length*)
- Metrike specifične za zadatak (eng. *task-specific*):
 - Prosečna preciznost gađanja meta (broj pogodaka / broj ispaljenih strela)
 - Prosečan broj ispaljenih strela po epizodi
 - Prosečan broj puta kada je agent otkriven ili napadnut od strane neprijatelja

Tokom evaluacije analiziraće se i proces učenja, pri čemu će se pratiti brzina konvergencije RL algoritma, tj. broj epizoda potreban da agent dostigne stabilne performanse. Sve metrike biće prikazane grafički i poređene za različite konfiguracije hiperparametara i funkcija nagrade.

Tehnologije

Za izradu projekta koristiće se Unity i ML-Agents biblioteka [2].

Literatura

[1] S. Russell i P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed., Pearson, 2020, pogl. 22.

[2] *ML-Agents Documentation*. [Online]. Dostupno: <https://github.com/Unity-Technologies/ml-agents/tree/develop/docs> [Pristupljeno: 22. 8. 2025].

[3] *OpenAI RL intro.* [Online] Dostupno:
https://spinningup.openai.com/en/latest/spinningup/rl_intro.html [Pristupljeno: 22. 8. 2025]